

Содержание отчета

I. Основные термины.....	2
II. Введение.....	3
III. Цели.....	4
IV. Удаление активности глаз из ЭЭГ сигнала.....	5
V. Топологический анализ данных	6
VI. Вычислительный эксперимент	7
VII. Вычисление мощности альфа-ритма и его доли среди остальных ритмов мозга	8
VIII. Классификатор KNN	10
IX. Заключение	12
X. Список литературы	13

Основные термины

- Эмоция — это психофизиологический процесс, вызванный сознательным или бессознательным восприятием ситуации или объекта.
- Аффективные вычисления — это область исследований, связанная с когнитивными вычислениями и искусственным интеллектом.
- Эмоциональный интеллект — сумма навыков и способностей человека распознавать эмоции, понимать намерения, мотивацию и желания других людей и свои собственные, а также способность управлять своими эмоциями и эмоциями других людей в целях решения практических задач.
- Двумерная модель Дж. Рассела [8] — двумерный базис, в котором каждая эмоция характеризуется знаком (valence) и интенсивностью (arousal).
- Valence (Валентность) — представляет качество/приятность эмоции и варьируется от неприятной (низкая валентность) до приятной (высокая валентность). Например, гнев и страх — это две разные эмоции, но обе имеют высокий уровень возбуждения/высокую интенсивность (arousal) и отрицательную валентность.
- Arousal (Интенсивность) — представляет собой возбуждение эмоции и колеблется от спокойного (низкая интенсивность) до возбужденного (высокая интенсивность).

Введение

Эмоциональные состояния связаны с самыми разнообразными человеческими чувствами, мыслями и поведением, поэтому они влияют на нашу способность действовать рационально в таких случаях, как принятие решений, восприятие и человеческий интеллект. Поэтому исследования по распознаванию эмоций с использованием эмоциональных сигналов усиливают системы мозгово-компьютерного интерфейса как эффективного субъекта для клинического применения и социальных взаимодействий человека. Физиологические сигналы используются для исследования эмоциональных состояний при рассмотрении естественных аспектов эмоций с целью выяснения терапии психологических расстройств, таких как расстройство аутистического спектра, синдром дефицита внимания с гиперактивностью и тревожное расстройство. В последние годы разработка систем распознавания эмоций на основе ЭЭГ-сигналов стала популярной темой исследований среди ученых, занимающихся когнитивистикой.

Цель аффективных вычислений состоит в том, чтобы заполнить этот пробел, обнаруживая эмоциональные сигналы, возникающие во время взаимодействия человека и компьютера, и синтезируя эмоциональные реакции.

Область применения исследования: маркировка видео с использованием аффективной информации может помочь рекомендательным и поисковым системам повысить их эффективность. Также данное исследование может найти свое применение в медицине. Например, лечении больных алекситимией (болезнью, связанной с проблемами передачи и описании своего эмоционального состояния), тревожно-депрессивными расстройствами и зависимостями (поскольку решение задачи о распознавании эмоционального состояния напрямую связано с этими отклонениями). Актуальность выбранного для проведения работы научного направления не вызывает сомнений из-за наличия нескольких областей применения исследования.

Цели

Основная цель исследования состоит в том, чтобы выявить особенности, которые помогут лучше всего различать эмоции. Мощность, энтропия, фрактальная размерность, статистические характеристики и вейвлет-энергия и др. были использованы для анализа. Исследуются эффекты этих особенностей и выявляются лучшие из них.

Были выявлены следующие задачи:

- 1) Анализ необходимой литературы и статей [6], [7] и др. :
 - А) Анализ признаков модели,
 - Б) Анализ методики,
 - В) Поиск необходимых технологий,
 - Г) Изучение библиотек языка,
 - Д) Консультации со специалистом,
 - Е) Сравнение и анализ источников;
- 2) Решение задачи распознавания закрытых и открытых глаз, удаление шумов.
- 3) Поиск наилучшей модели для построения предсказаний.
- 4) Запись ЭЭГ сигнала у испытуемых в лаборатории.
- 5) Анализ точности и корректности модели.
- 6) Выводы, полученные в ходе эксперимента.

Так как проект является групповым, задачи распределяются между участниками. Каждому дается план и ожидаемые результаты. Таким образом, каждый участник выполняет часть работы и отчитывается раз в неделю о результатах. Затем, когда все необходимые теоретические источники проанализированы, участники начинают совместно работать над написанием модели, классифицирующей эмоции и ее анализом.

Передо мной была поставлена задача удаления шума активности глаз. Для решения я воспользовался статьей [2], изучил библиотеку MNE-Python [4]. Затем, я исследовал Топологический анализ данных для анализа временных рядов. Также, мы с коллегами провели вычислительный эксперимент для поиска эффективных признаков и оценки предсказательных моделей.

Удаление активности глаз

В приведенной статье [2] используется метод ICA (Independent Component Analysis). В двух словах, ICA разлагает многоканальные ЭЭГ-записи на максимально независимые компоненты. Компоненты, представляющие окулярную активность, могут быть идентифицированы и устранены для восстановления безартефактных ЭЭГ-сигналов. ICA может хорошо отделить глазные компоненты от компонентов мозга, если доступно много ЭЭГ каналов (что, в свою очередь, требует относительно большого количества образцов данных). Более чистое отделение также означает, что при удалении глазных компонентов будет удалена меньшая мозговая активность.

Ниже представлены две функции, выполняющие требуемую задачу. Одна из них использует регрессионный подход, а другая метод ICA.

```
def remove_eye_activity_ICA(data):
    good_channels = [2, 3, 4, 5, 8, 12, 14, 32, 30, 26, 22, 21, 20, 18]
    ch_names = ["AF3", "F3", "F7", "FC5", "T7", "P7", "O1", "O2", "P8", "T8", "FC6", "F8", "F4", "AF4"]
    EOG_channels = [33, 34, 35, 36]
    eeg = []

    for ch in good_channels:
        eeg.append(np.array(data[ch]))

    for ch in EOG_channels:
        eeg.append(np.array(data[ch]))

    eeg = np.array(eeg) * 10e-6          #in volts

    info = mne.create_info(ch_names, 128, ch_types=["eeg"] * 14 + ["eog"] * 4)
    raw = mne.io.RawArray(eeg, info)

    raw_tmp = raw.copy()
    raw_tmp.filter(1, None)

    ica = mne.preprocessing.ICA(method="picard",
                                fit_params={"extended": True},
                                random_state=1)

    ica.fit(raw_tmp)
    #TODO: WHAT ICA'S ?
    #ica.exclude = [1]

    raw_corrected = raw.copy()

    return raw_corrected.get_data()

def remove_eye_activity_regr(data):
    good_channels = [2, 3, 4, 5, 8, 12, 14, 32, 30, 26, 22, 21, 20, 18]
    EOG_channels = [33, 34, 35, 36]
    eeg = []
    for ch in good_channels:
        eeg.append(np.array(data[ch]))

    for ch in EOG_channels:
        eeg.append(np.array(data[ch]))

    eeg = np.array(eeg) * 10e-6
    eeg1 = eeg.copy()
    info = mne.create_info(18, 512, ch_types=["eeg"] * 14 + ["eog"] * 4)
    raw1 = mne.io.RawArray(eeg, info)
    raw2 = mne.io.RawArray(eeg1, info)
    bip = np.array([[ -1, 1, 0, 0], [0, 0, -1, 1]])
    raw1_eog = bip @ raw1[14:, :][0]
    raw2_eog = bip @ raw2[14:, :][0]
    raw1_eeg = raw1[14, :][0]
    raw2_eeg = raw2[14, :][0]
    b = np.linalg.inv(raw1_eog @ raw1_eog.T) @ raw1_eog @ raw1_eeg.T
    eeg_corrected = (raw2_eeg.T - raw2_eog.T @ b).T
    raw3 = raw2.copy()
    raw3.data[14, :] = eeg_corrected
    return np.array(raw3.to_data_frame().T[1:])
```

Топологический анализ данных и его применение для анализа данных временных рядов.

Топологический анализ данных (Topological Data Analysis) — метод анализа данных с использованием геометрии и методов алгебраической топологии. Он эффективен для анализа больших, высокоразмерных и богатых характеристиками данных, поскольку отображает свойства, связанные с формой, такие как наличие или отсутствие петель в наборах данных, и таким образом помогает выявлять ключевые закономерности. Так как TDA сохраняет важные характеристики и взаимосвязи между точками наборов данных, можно сказать, что она в основном занимается сжатием данных без потерь и в чистом виде.

В статье, изучаемой мной, упоминаются две технологии анализа: Mapper и Persistent homology.

Mapper — это технология, которая из набора данных выделяет отличительные особенности (фичи) и выдает их в виде графа. Для этого Mapper группирует важные части данных в виде узлов и соединяет узлы со смежными данными ребрами и преобразует набор данных в граф. Mapper может визуализировать распределение данных, выводя набор данных в виде двумерного графа.

Технология реализована во многих библиотеках языков программирования, например, `scikit-tda`[10] или библиотека `kmapper`, реализующая алгоритм на основе модели кластеризации DBSCAN из пакета `sclearn.clustering`.

Persistent homology — это технология, которая может численно передать форму данных в деталях. При анализе данных важно понять их расположение, но бывают случаи, когда обычные статистические показатели не могут передать эту характеристику.

Вычислительный эксперимент

Мы провели ряд экспериментов для оценки предсказательных моделей и поиска эффективных признаков для этих моделей. Мы извлекли ряд статистических, топологических, энтропических и фрактальных признаков из нашего датасета с помощью соответствующих библиотек. Далее мы обучили наши модели на извлеченных признаках и определили 50 наиболее важных из них. Как мы выяснили, повторное обучение модели может изменить вклад, который вносит каждый из признаков и проведя эксперимент 4 раза, мы выделили среди них наиболее устойчивые к изменениям.

Channel	Description	Type
O2	samp_entropy	Entropy
T8	spec_entropy	Entropy
F7	petrosyan	Fractal Dimension
O2	Hig	Fractal Dimension
F4	power_8_12_abs	Statistic
FC5	median	Statistic
FC6	freq_mean_alpha	Statistic
FC6	lyap_r	Statistic
FC6	power_8_12_abs	Statistic
O1	lyap_r	Statistic
O2	first_der	Statistic
O2	second_der	Statistic
O2	wvlt_gamma	Statistic
T8	lyap_r	Statistic
F7	PL_1ch	Topological
FC6	PL_1ch	Topological
P8	PE	Topological

Вычисление мощности альфа-ритма и его доли среди остальных ритмов мозга.

План :

- I. Описание альфа-ритма.
- II. Замечания, сделанные в ходе исследования.
- III. Выводы.

Частотный анализ (спектральный анализ) — наиболее распространенный метод анализа ЭЭГ и является стандартным и одним из самых простых и эффективных методов. Он позволяет трактовать информацию, содержащуюся в частотных характеристиках сигналов ЭЭГ. Это достигается путем применения статистических методов и методов преобразования Фурье. Среди всех спектральных методов наиболее часто используется анализ спектральной плотности мощности, поскольку спектр мощности отражает «частотное содержание» сигнала или распределение мощности сигнала в зависимости от частоты [13].

I. Альфа-ритм или альфа-волны (англ. alpha rhythm, alpha wave, α -rhythm) — нормальная ритмическая активность ЭЭГ, регистрирующаяся в области первичных или вторичных зон сенсорной коры при открытых или закрытых глазах в состоянии покоя у 85-95% здоровых взрослых. При активации сенсорных областей коры альфа-ритм угнетается. У здорового человека альфа-ритм является доминирующим (т.е. преобладает по амплитуде) в области теменной, затылочной, а также сенсомоторной коры, где отдельно выделяют ти- или сенсомоторные ритмы. Частота альфа-ритма варьирует в пределах от 8 до 13 Гц. Синусоидальная форма амплитуды альфа-волн может варьировать, но у взрослых обычно около 30-50 мкВ. Блокируется или ослабляется при повышении внимания (в особенности зрительного) или мыслительной активности. [11]

II. Напомню, что канал FC6 находится на височной доле мозга, отвечающей за распознавание и интерпретацию звуков.

Средние значения альфа - ритма представлены в таблице:

AF3	F3	F7	FC5	T7	P7	O1	O2	P8	T8	FC6	F8	F4	AF4	arousal
0,043516	0,052226	0,043445	0,035371	0,047177	0,03591	0,042189	2,32515	0,052472	0,041162	0,04839	0,043637	0,041835	0,04719	6,605495
0,05557	0,054533	0,049336	0,041771	0,047509	0,042054	0,053672	2,192285	0,059664	0,043392	0,052738	0,050948	0,040868	0,053324	2,941271

AF3	F3	F7	FC5	T7	P7	O1	O2	P8	T8	FC6	F8	F4	AF4	valence
0,050655	0,051695	0,048737	0,036242	0,048399	0,039969	0,048548	2,307299	0,058435	0,043375	0,054469	0,051163	0,040954	0,051877	6,439081
0,043223	0,055508	0,040131	0,04035	0,045366	0,035021	0,042687	2,221388	0,049303	0,039538	0,042122	0,037839	0,0424	0,045185	2,901509

Лучше всего альфа-ритм выражен в затылочных и теменных отделах, по направлению кпереди амплитуда его постепенно уменьшается, что можно заметить по значениям с затылочного канала O2.

Средние значения доли альфа - ритма среди всех частот представлены в таблице :

AF3	F3	F7	FC5	T7	P7	O1	O2	P8	T8	FC6	F8	F4	AF4	arousal
0,166746	0,165778	0,162194	0,166045	0,165034	0,163164	0,163533	0,192508	0,166976	0,164915	0,164908	0,163207	0,166049	0,167387	6,605495
0,166288	0,165755	0,162288	0,16758	0,164955	0,163186	0,164527	0,193154	0,167227	0,165382	0,166163	0,163856	0,166386	0,167117	2,941271

AF3	F3	F7	FC5	T7	P7	O1	O2	P8	T8	FC6	F8	F4	AF4	valence
0,166819	0,166216	0,16257	0,16693	0,165491	0,163227	0,16388	0,192042	0,167371	0,165268	0,165834	0,1635	0,165843	0,16749	6,439081
0,166153	0,164986	0,16163	0,16605	0,164151	0,163075	0,163934	0,193984	0,166537	0,16477	0,164556	0,163352	0,166754	0,16693	2,901509

Данный признак нам посоветовал применить и проанализировать В.В. Косоногов. Как видно из таблицы доля альфа-ритма в среднем составляет 16%, что неудивительно, так как испытуемые находились под умственной нагрузкой и на бета-ритме эти значения выше:

AF3	F3	F7	FC5	T7	P7	O1	O2	P8	T8	FC6	F8	F4	AF4	arousal
0,369707	0,356989	0,356273	0,358965	0,348993	0,356027	0,370072	0,346682	0,354001	0,353456	0,350728	0,350862	0,362609	0,353833	6,605495
0,365134	0,356926	0,346716	0,35463	0,343418	0,353005	0,367466	0,348393	0,346148	0,349253	0,348421	0,345191	0,360471	0,34407	2,941271

III. Выводы.

Альфа-ритмы наиболее информативны при анализе электроэнцефалограммы при прослушивании музыки, согласно теории генерации альфа-волн, представленной выше, любое увеличение сигнала на сенсорном входе должно подавить соответствующий альфа-ритм. Реакцию подавления называют реакцией десинхронизации, потому что высокоамплитудные альфа-волны можно рассматривать как результат синхронизации в нейронных сетях. Именно благодаря десинхронизации альфа-ритмов в ответ на музыкальные стимулы модели получилось обучиться видеть эти паттерны и выявлять их в ходе предсказаний.

Классификатор KNN

Классификация — это процесс предсказания класса заданных данных, в нашем случае бинарное определение *valence* и *arousal* для каждого отрезка данных.

Сейчас я расскажу кратко, как работает KNN classifier. *K* — параметр количества ближайших соседей (Nearest Neighbors). Каждый отрезок данных представляет собой вектор в *N*-мерном пространстве, где *N* — это количество фичей. Известен некоторый набор объектов, для которого заранее определен класс. Это множество есть обучающая выборка. На её основе, проводится предсказание классов тестовой выборки. Для классификации:

1. Найдем расстояние до объектов из тренировочной выборки.
2. Выберем *k* наиболее близких соседей.
3. Класс классифицируемого объекта — это класс, наиболее часто встречающийся среди *k* ближайших соседей.


Я применил алгоритм с помощью библиотеки *sklearn* [12]. Рассмотрим главный параметр:

1. *n_neighbors* int, default=5. Выбор количества соседей. Заметим, что при *k* = 1, алгоритм становится неустойчивым к выбросам, а при *k* = *n*, наоборот чрезмерно устойчив и вырождается в константу. [12]

С помощью метода *cross_val_score* подберем оптимальный параметр *k*:

```
from sklearn.model_selection import cross_val_score
from tqdm import tqdm
scores1 = []
for i in tqdm(range(1, 500)):
    neigh = KNeighborsClassifier(n_neighbors=i)
    cv_scores = cross_val_score(neigh, X_train_ar_2.fillna(0), y_train_ar_2, cv=5)
    scores1.append(np.mean(cv_scores))
```

```
index = np.array([i for i in range(1, 500)])
plt.plot(index, scores1)
plt.xlabel("K parameter")
plt.ylabel("Score")
plt.show()
```



По графику видно, что оптимальный параметр k лежит в промежутке $[40; 60]$. При $k = 55$, достигается максимальное значение score.

С помощью различных метрик оценим нашу модель. Precision — доля объектов, названных классификатором положительными и при этом являющимися положительными (показывает умение отличать один класс от других классов). Recall — доля объектов положительного класса из всех объектов положительного класса (показывает умение обнаруживать определенный класс). False Positive Rate — ошибки классификатора первого рода. False Negative Rate — ошибки классификатора второго рода. Loss — логистическая функция ошибки.

- Accuracy: 0.659375
- Precision: 0.9560975609756097
- Recall: 0.6621621621621622
- F1 Score: 0.782435129740519
- Loss: 11.764793198194175
- False Positive Rate: 0.375
- False Negative Rate: 0.33783783783783783

Стоит отметить, что результат неплохой, но уступает результатам, которые показали алгоритмы, которые использовали мои коллеги — CatBoost и Naive Bayes classifier. Метрика Accuracy в них чуть выше 0.7, а это неплохо, учитывая объем данных. Но есть возможность увеличить объем данных, если разрезать их на 10 секундные отрезки, что теоретически может повлиять на точность в положительную сторону, как это сделали R.Nawaz, H.K. Cheach, Humaira Nisar, V. V. Yap. [6].

Заключение

В ходе работы над проектом были выделены и описаны особенности, которые помогут лучше всего различать эмоции. Мою и моими коллегами были применены несколько моделей из библиотеки `scikit-learn` и модель `CatBoost`. В результате применения `CatBoost` была получена точность 70%, что уступает точности с опорного исследования, но обходит точности остальные использованные модели.

Источники

1. Зенков Л. Р. Клиническая электроэнцефалография (с элементами эпилептологии) / Зенков Л. Р. — 3-е изд.. — Москва: Изд-во МЕДпресс-информ, 2004. — 368 с. — 3000 экз. — ISBN 5-901712-21-8 стр. 12.
2. Удаление активности глаз. <https://cbrnr.github.io/posts/removing-eog-ica/> Открытая статья. Дата обращения: 8.02.2021.
3. Код проекта. https://github.com/NikitaRudenkiy/EEG_EMOTION_RECOGNITION Открытый сайт. Дата обращения: 8.02.2021.
4. Библиотека MNE-Python. <https://mne.tools/stable/index.html>. Открытый сайт. Дата обращения: 8.02.2021.
5. PsychoPy. <https://www.psychopy.org/about/overview.html>. Открытый сайт. Дата обращения: 8.02.2021.
6. R.Nawaz, H.K. Cheach, Humaira Nisar, V. V. Yap. (2020). Comparison of different feature extraction methods for EEG-based emotion recognition. Открытая статья. Дата обращения: 01.02.2021.
7. DEAP DATASET for emotion analysis. <http://www.eecs.qmul.ac.uk/mmv/datasets/deap/download.html>. Открытая статья. Дата обращения: 07.02.2021.
8. Russell, J. A. (1980). A circumplex model of affect. *Journal of Personality and Social Psychology*, 39(6), 1161–1178.
9. Y. Umeda et al. FUJITSU SCIENTIFIC & TECHNICAL JOURNAL, Vol. 55, No. 2, pp. 65–71 (2019) AI Zinrai Supporting Digital Innovation: Topological Data Analysis and Its Application to Time-Series Data Analysis.
10. scikit-tda. <https://github.com/scikit-tda/kepler-mapper>. Открытый сайт. Дата обращения: 27.02.2021.
11. <https://cmi.to/ритмы-ээг/альфа-ритмы/> Открытый сайт. Дата обращения: 28.05.2021
12. <https://scikit-learn.org/stable/modules/classes.html#module-sklearn.neighbors> Открытый сайт. Дата обращения: 28.05.2021
13. <https://cmi.to/анализ-ээг/> Открытый сайт. Дата обращения: 28.05.2021.